

Deterministic AST Healer 的安全修復邊界

以16題、3模型、4條件、5種子共960個生成單元驗證 (Math16 Pilot-02)

【研究問題】

AI生成Python程式失敗時，
哪些錯誤可由確定性AST Healer
安全修復？哪些必須Abstain？


【實驗設計】

- 16題 × Integer / Polynomial / Radical / Fraction
- 3模型：Gemini 3.5 Flash、Qwen 3.5 4B、Qwen 3.5 9B
- 4 Prompt 條件 (Ab1 / Ab2g / Ab2d+api / Ab2d+spec) × 5 Seeds = 960 個生成單元

【核心結果】


- Gemini Baseline：289/320 (90.3%)
- Qwen 4B Baseline：78/320 (24.4%)
- Qwen 9B Baseline：101/320 (31.6%)

三模型 Baseline 端到端通過率




註：Gemini為Tier 2描述性參照；4B與9B為Tier 1配對比較。Baseline不代表Healer可修復窗口。
Fig.1 三模型 Baseline 通過率

四數學家族的 Qwen 4B / 9B Baseline 通過數



註：Family差異屬探索性；Polynomial反向結果不可外推為9B整體能力較差；Fraction差距不可只解讀為數學能力。
Fig.3 四 Family × 4B/9B 通過數

Qwen 4B與9B的320格配對結果
2x2 配對陣列 (n = 320)



統計量對照與推論說明

【配對統計與不一致分析】

- 9B-only PASS: 49 格
- 4B-only PASS: 26 格
- Net Cell Gain (Δ): +23 格
- Paired Risk Diff: +7.19%

【不確定性與雙重指標】


- Exact McNemar: $p = 0.010582^*$
- Cluster Bootstrap 95% CI: [-0.94%, +14.38%]

解讀：Cell-level discordant 方向
偏向 9B，但 Task-level 外推
仍具抽樣不確定性。

註：Cell-level discordant 方向偏向 9B，但 task-level 外推仍有不確定性。* exact McNemar p 在類別層級顯著。

Fig.4 Tier 1 配對分析 (McNemar $p=0.011$, CI=[-0.94%, +14.38%])

FAIL數量與可安全修復窗口



註：在本次320個測試單元中觀察到Regression=0。Gemini與9B未命中規則主動Abstain (Eligible=0)。

Fig.5 Healer Eligibility 邊界 (Primary=5格 / Post-hoc=6格)

【結論與限制】

- Deterministic AST Healer 不是第二個解題模型，而是只在「修法唯一、局部、可驗證」的窄小窗口介入；其餘情況主動 Abstain。
- Healer 像球場最遠邊界的小柵欄，只攔住少量即將出界且方向明確的球，不代替球員重新比賽。
- eligible=0 不代表沒有失敗，只代表凍結規則在本次320個測試單元中未命中；Regression=0 為本次觀察結果，非保證。
- Family差異 (Polynomial反向) 為探索性，不可外推為9B整體弱於4B；Fraction差距不可只解讀為數學能力差異。

【統計摘要】 9B-only=49格 · 4B-only=26格 | Paired Risk Diff=+7.19% | Exact McNemar $p=0.010582$ | Task-clustered Bootstrap 95% CI=[-0.94%, +14.38%]
Cell-level方向偏向9B，但task-level跨題目外推仍有不確定性 (CI下界 < 0)。 本分析屬Primary Tier 1，Family breakdown屬Post-hoc探索，二者不可混用。