

AI生成程式失敗時，哪些錯誤可由Deterministic AST Healer安全修復？哪些必須Abstain？

16題 × 3模型 × 4條件 × 5 seeds = 960 cells | Primary 與 Post-hoc 嚴格分帳

Gemini Baseline
289/320


Fig.4 Tier 1 配對分析

Qwen 4B Primary Healer
83/320
(救回5格)

Qwen 9B Baseline
101/320

Fig.1 Baseline 通過率

Qwen 4B/9B 配對結果 (n=320)



統計摘要

9B-only PASS: 49 格

4B-only PASS: 26 格

Net Gain: +23 格 (+7.19%)

Exact McNemar:

p = 0.010582 *

Cluster Bootstrap CI:

[-0.94%, +14.38%]




Fig.3 Family 差異 (探索性)





Fig.5 安全修復窗口



- ① Healer 只在修法唯一、局部、可驗證的窄小窗口介入；其餘主動 Abstain。
- ② 4B Primary 救回 5 格 (83/320) ； Post-hoc 機制驗證額外 6 格 (84/320) ；本次觀察到 Regression=0。
- ③ 9B cell-level 方向偏優 (+23 格) ，但 task-clustered CI 跨 0，跨題外推仍具不確定性。

Healer 像球場最遠邊界的小柵欄，不代替球員重新比賽。

【統計】 Exact McNemar p = 0.010582 | Task-clustered Bootstrap 95% CI = [-0.94%, +14.38%] | Primary/Post-hoc 嚴格分帳，Gemini & 9B Eligible=0 | Family差異屬Post-hoc探索性，不可混用