

AI生成程式失敗時，哪些錯誤可由Deterministic AST Healer安全修復？哪些必須Abstain？

16題 × 3模型 × 4條件 × 5 seeds = 960 cells | Primary 與 Post-hoc 嚴格分帳

Gemini Baseline

289/320

Fig.4 Qwen 4B/9B 配對分析 (McNemar $p=0.011$ · CI=[-0.94%,+14.38%])

Qwen 4B Primary


83/320 (+5格)

Qwen 9B Baseline

101/320

Fig.1 Baseline 通過率

Qwen 4B/9B 配對結果 (n=320)



統計摘要

9B-only PASS: 49 格

4B-only PASS: 26 格

Net Gain: +23 格 (+7.19%)

Exact McNemar:

$p = 0.010582^*$

Cluster Bootstrap CI:

[-0.94%, +14.38%]






Fig.5 安全修復窗口 (Primary 救回5格)



Primary rescue=5格(83/320) ; Regression=0

Family 差異 (探索性)



※ 探索性，不可外推

① Healer 只在修法唯一、局部、可驗證的窄小窗口介入；其餘情況主動 Abstain。

② 4B Primary 救回 5 格 (83/320) ； Post-hoc 機制驗證額外 6 格 (84/320) ；本次觀察到 Regression=0。

③ 9B cell-level 方向偏優 (+23 格) ，但 task-clustered CI 跨 0，跨題目外推仍具不確定性。