

Small but Precise: Outperforming Large Models through Engineered Self-Healing

研究問題：AI生成程式大模型，輸出結果可由 Deterministic AST Healer 安全修復？輸出結果 Adversarial 16題 × 3模型 × 4條件 × 5 seeds = 960 cells

Gemini 3.5 Flash
289/320 PASS
雲端強模型參照

Qwen 3.5 4B Primary
83/320 PASS
Baseline 78 + 救回5格

Qwen 3.5 9B
101/320 PASS
Baseline / Final

研究動機

小模型部署常遇語法、契約、API、執行與語意層失敗。
目標：劃定硬性 AST 修復可安全介入的邊界。

Healer 定位：只修窄小窗口

不是第二個解題模型，不重寫解題邏輯。
僅在修法唯一、局部、可驗證時介入；否則 Abstain。

研究設計

16題 / 四 family：Integer、Polynomial、Radical、Fraction
三模型：Qwen 4B、Qwen 9B、Gemini 3.5 Flash
四條件：Ab1、Ab2g、Ab2d+api、Ab2d+spec


Baseline → Eligibility → Healer / Abstain

LLM 程式生成 → Evaluator Baseline → Eligibility 靜態審查
→ Active Healer (唯一、局部、可驗證) 或 Abstain

Primary / Post-hoc 分帳

4B Baseline = 78/320
Primary：83/320，rescue=5 (唯一正式預註冊結論)
Post-hoc：84/320，total rescue=6
相較 Primary 僅多 1 PASS
Gemini：Primary 289/320；Post-hoc 306/320

Figure 4 Tier 1 配對分析 (主視覺)



配對核心訊息

BOTH_PASS 52 | FOUR_B_ONLY 26 | NINE_B_ONLY 49 | BOTH_FAIL 193
McNemar $p=0.010582$ • Cluster CI=[-0.94%, +14.38%]
9B-only 49 vs 4B-only 26；外推至未知題型仍具不確定性。

Figure 1 Baseline





Figure 5 Eligibility / Rescue



Healer 邊界

4B Eligible=10，Primary rescue=5；Gemini / 9B Eligible=0。
無唯一安全修法時，系統 Abstain，不盲目修改。

Figure 3 Family 差異




Figure 2 Prompt 條件





Figure 2 分帳警語

Gemini 80/80 為 Post-hoc 機制驗證；Primary spec-v1=63/80。

Qwen 採 spec-v2，不作完全同條件 Primary 因果推論。

Figure 6 安全概念圖



五項主要發現

- Baseline能力與可修復窗口不同。
- 4B 有窄小、可驗證 repair window。
- 9B 整體較高，但 family 非單調。
- Prompt 效果依模型、版本與部署條件而異。
- Abstain 是重要安全能力。

三項限制

McNemar 顯著但 Cluster CI 跨0；Fraction 為探索性；

Regression=0 / Eligible=0 僅限本次實驗測試。

一句結論

Healer 六窄小窗口；無確定解即 Abstain。