

Small but Precise: Outperforming Large Models through Engineered Self-Healing

Math16 Pilot-02 子實驗 • AI生成程式失敗時，哪些錯誤可由 Deterministic AST Healer 安全修復？哪些必須 Abstain？
16題 × 3模型 × 4條件 × 5 seeds = 960 cells

Gemini 3.5 Flash

289/320

PRIMARY

Qwen 4B PRIMARY

83/320

救回 5 格

Qwen 9B

101/320

BASELINE / FINAL

研究設計

16題 / 四 family：Integer、Polynomial、Radical、Fraction
三模型：Qwen 4B、Qwen 9B、Gemini 3.5 Flash
四條件：Ab1、Ab2g、Ab2d+api、Ab2d+spec

Healer 只修窄小且可驗證的窗口

不是第二個解題模型，不重寫解題邏輯。
修法唯一、局部、可驗證才介入；否則 Abstain。

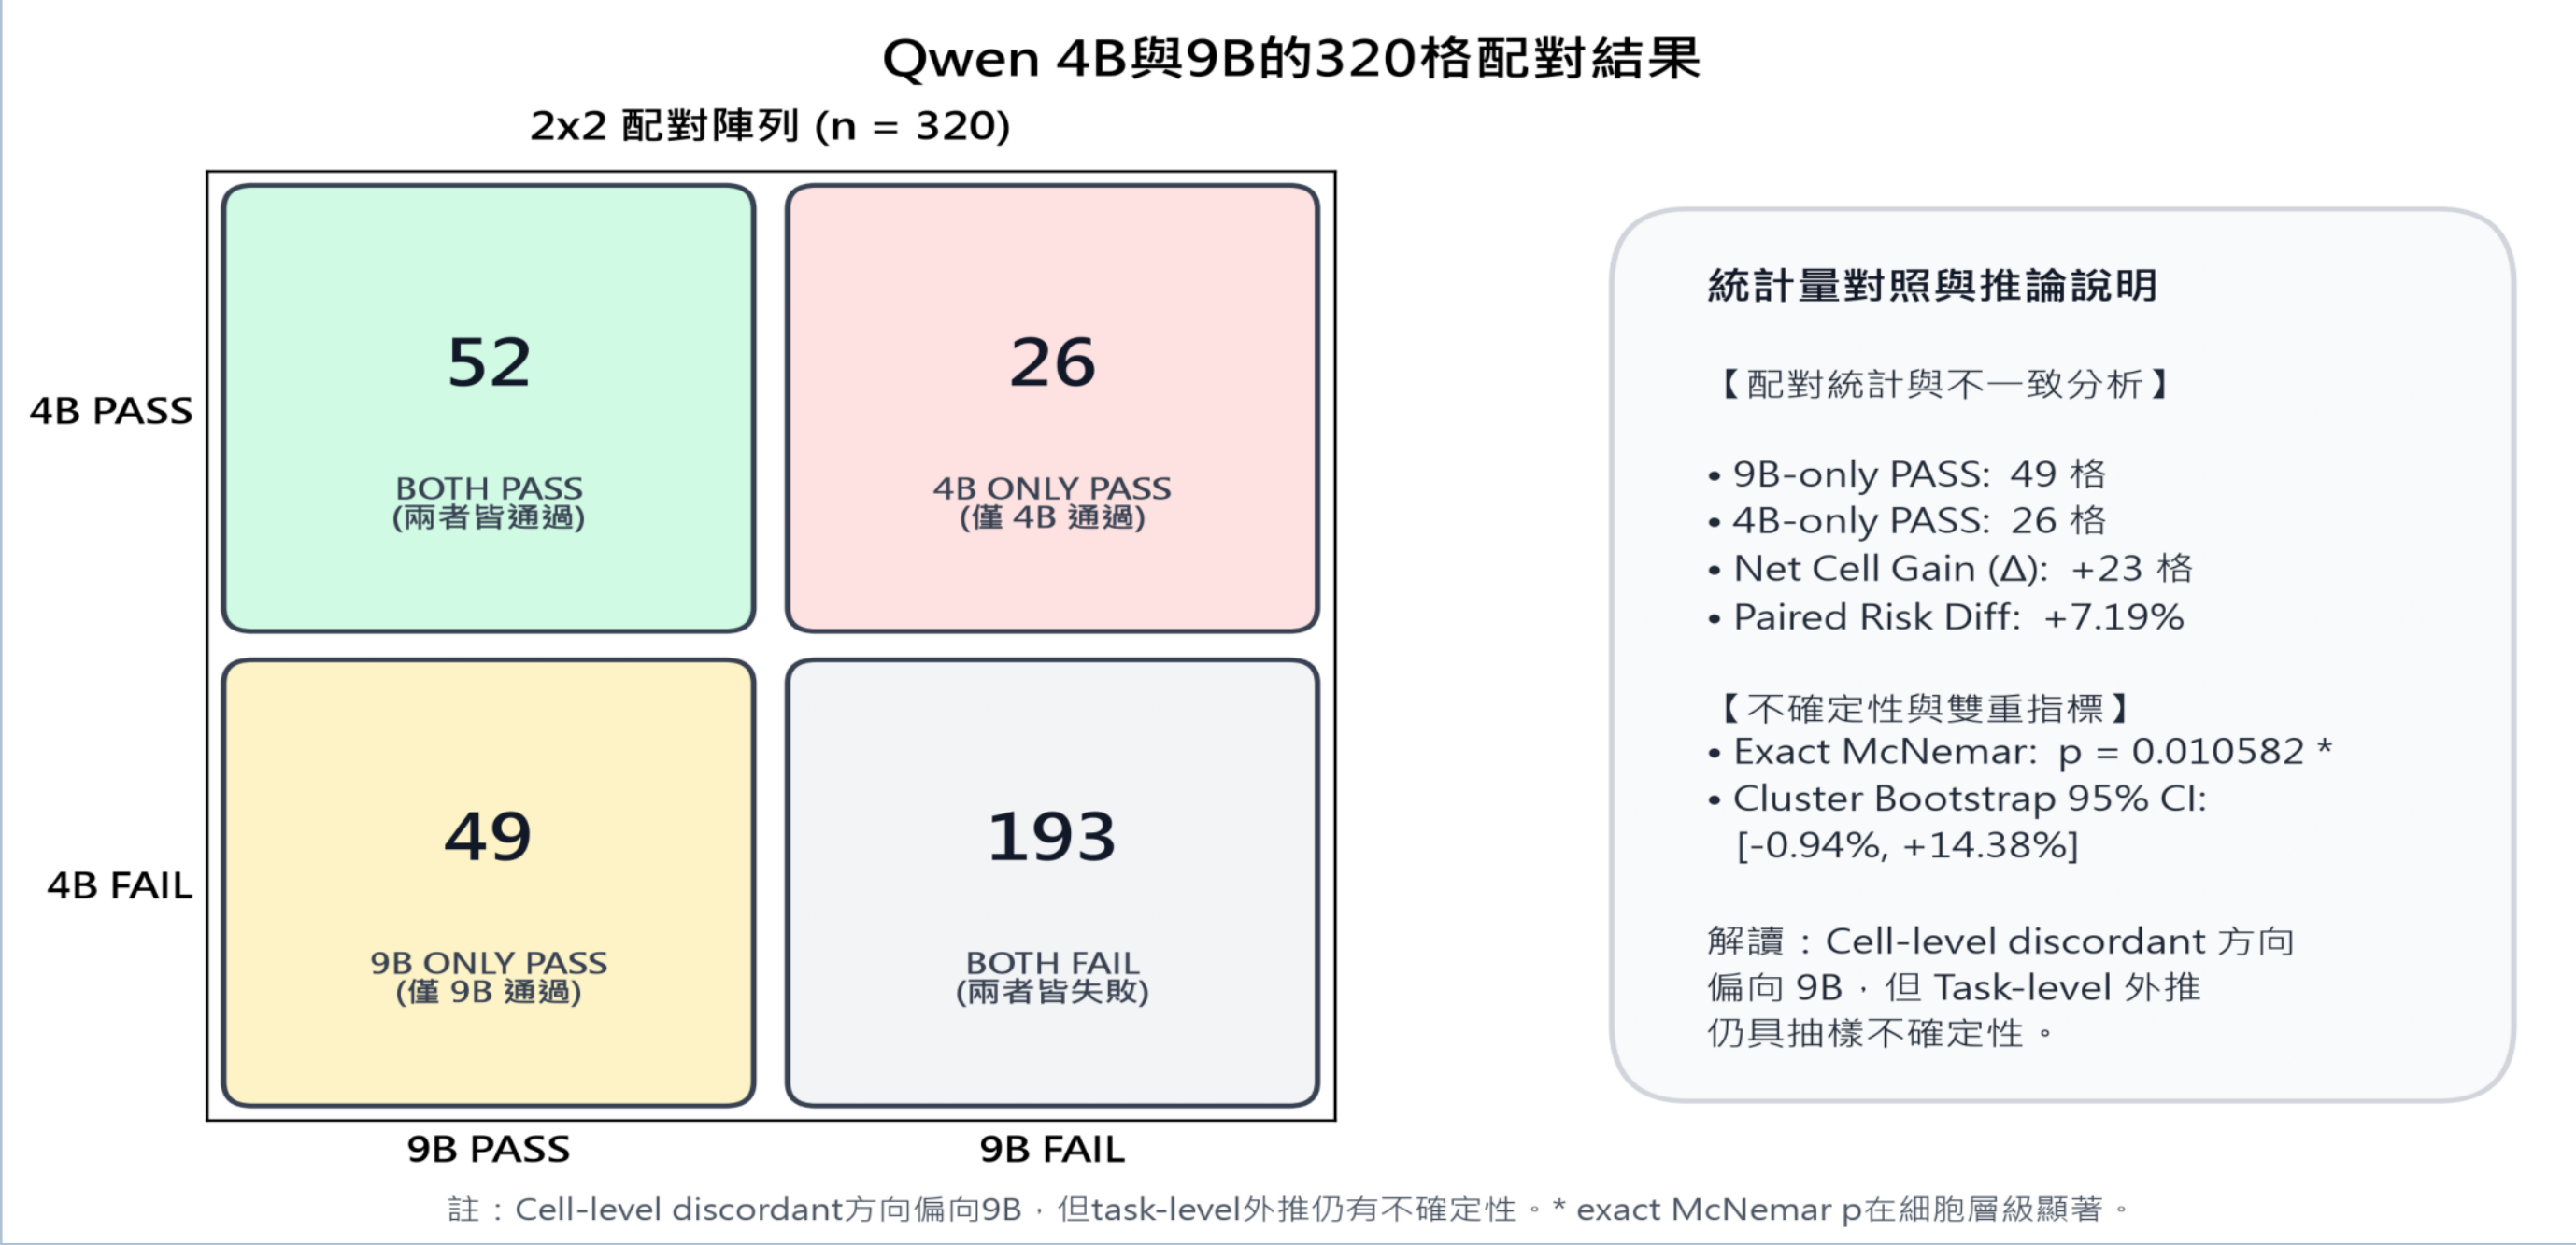
Baseline → Eligibility → Healer / Abstain

生成 → Evaluator → 靜態審查 → 修復或放棄盲猜

Primary / Post-hoc 分帳

4B Baseline 78/320
Primary 83/320 · rescue=5
Post-hoc 84/320 · total rescue=6 (僅多1 PASS)
Gemini Primary 289/320；Post-hoc 306/320


Figure 4 Tier 1 配對分析 (最大主視覺)



49 vs 26：9B-only vs 4B-only

BOTH_PASS 52 • BOTH_FAIL 193 • McNemar $p=0.010582$ • Cluster CI=[-0.94%, +14.38%]

Figure 1 Baseline



4B Eligible=10 · Primary rescue=5；Gemini / 9B Eligible=0

無唯一安全修法時，Healer Abstain，不盲目修改。

Figure 3 Family 差異




Figure 2 Prompt 條件


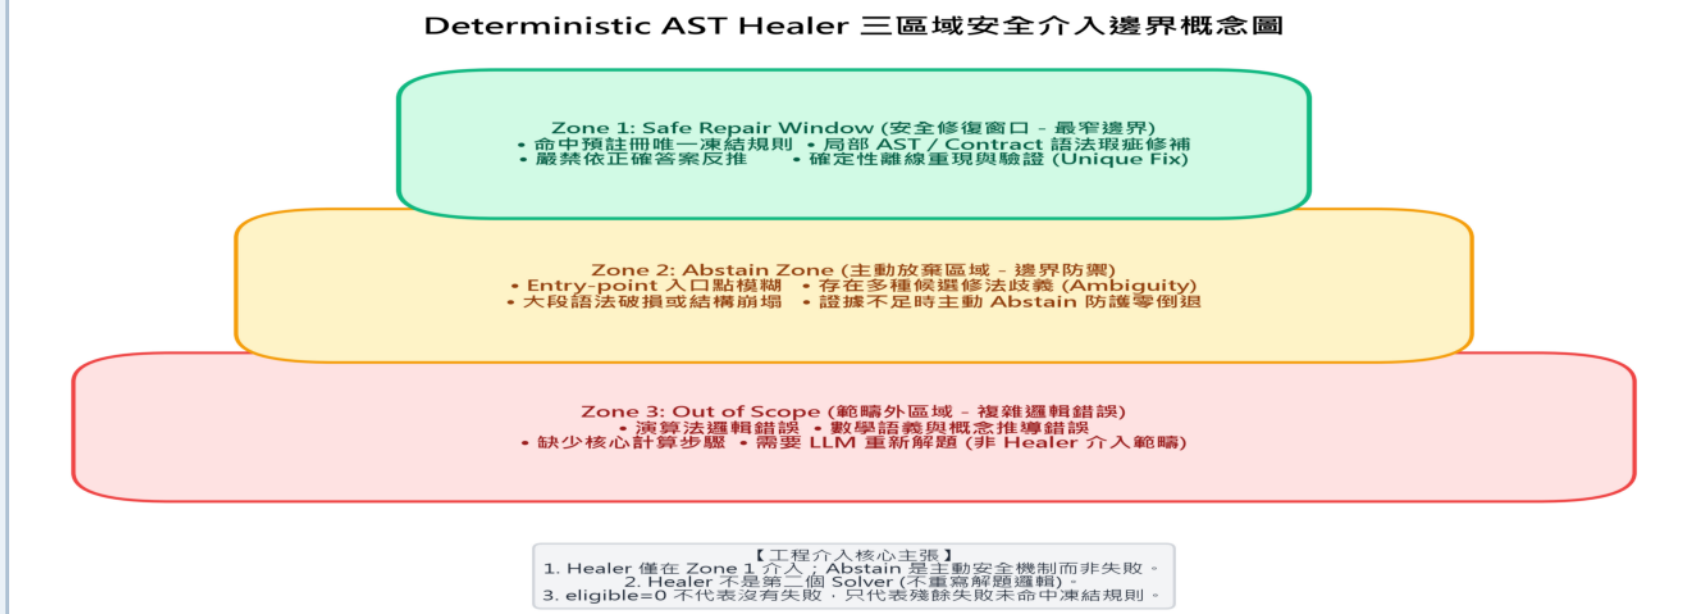


Figure 2 分帳警語

- Gemini 80/80 = Post-hoc
- Primary spec-v1 = 63/80
- Qwen = spec-v2
- 不作完全同條件因果推論

Figure 6 安全概念圖



五項主要發現

- Baseline 與修復窗口不同
- 4B 有窄小 repair window
- 9B family 非單調
- Prompt 效果依模型 / 版本而異
- Abstain 是重要安全能力

結論

Healer 只修窄小且可驗證的窗口。

三項限制

1. Cluster CI 跨 0，外推有限 • 2. Fraction 為探索性，非純數學能力差異 • 3. Regression=0 / Eligible=0 僅限本次