

Deterministic AST Healer 的安全修復邊界

AI生成程式失敗時，哪些錯誤可由 Deterministic AST Healer 安全修復？哪些必須 Abstain？

16題 × 3模型 × 4條件 × 5 seeds = 960 cells | 呈現序 Gemini→9B→4B | Baseline 79→Final 85


Gemini Baseline
289/320

Qwen 9B Baseline
101/320

Qwen 4B Final
85/320 (rescue=6)

Fig.4 Qwen 4B/9B 配對分析 (McNemar $p=0.015440$ · CI=[-1.56%,+14.37%])

Qwen 4B/9B 配對結果 (n=320)



統計摘要

9B-only: 49 格

4B-only: 27 格

Net: +22 格 (+6.88%)

McNemar:

$p = 0.015440^*$

Bootstrap CI:

[-1.56%, +14.37%]

Fig.1 Baseline 通過率 (Gemini→9B→4B)




Fig.2 Prompt 條件 (Gemini Ab2d+spec = 80/80*)




Fig.5 安全修復窗口 (Verified rescue=6)





Fig.3 Family 差異 (探索性; Polynomial 4B=17/80) ; Regression=0



※ 探索性

① Healer 只在修法唯一、局部、可驗證的窄小窗口介入；其餘情況主動 Abstain。

② 4B : 79/320 → 85/320 ; Verified rescue=6 ; Regression=0 (Primary 84 不作主表)。

③ 9B cell-level 正向偏優 (+22 格) · 但 task-clustered CI 跨 0 · 跨題外推具不確定性。

Healer 像球場最遠邊界的小柵欄，不代替球員重新比賽。

* Gemini 3.5 Flash 的 Ab2d+spec 採 Post-hoc spec-v2，結果為 80/80；原 Primary spec-v1 為 63/80。

【統計摘要與限制】

- Exact McNemar: $p = 0.015440^*$
- Task-clustered Bootstrap 95% CI: [-1.56%, +14.37%]
- Verified rescue=6；呈現序 G→9B→4B
- Fig.2 : Gemini Ab2d+spec = 80/80*
- Family 差異屬 Post-hoc 探索性，不可外推